

Trabalho Prático I

INTRODUÇÃO

Com este trabalho da Disciplina de Integração de Sistemas de Informação (ISI) pretende-se focar a aplicação e experimentação de ferramentas em processos de ETL (*Extract, Transformation and Load*), inerentes a processos de Integração de Sistemas de informação ao nível dos dados.

Pretende-se que sejam desenvolvidos processos de ETL que envolvam *scripts* próprias ou que recorram a ferramentas disponíveis como o Pentaho Kettle, Microsoft SQL Server Integration Services (MSSIS), Knime, Talend open studio, ou outras. Ferramentas complementares como *Node-RED*¹, *Home-Assistant*² ou outras do género, poderão também ser exploradas e integradas nos processos.

MOTIVAÇÃO

Uma vez que os processos de negócio não param de se reconfigurar, as empresas enfrentam desafios constantes de análise e aquisição de novas soluções informáticas. A necessidade de rentabilizarem anteriores aquisições, tanto pelo investimento financeiro envolvido como pela dependência dos processos, dos dados, etc., que delas fazem parte, as empresas procuram formas capazes de analisarem mais-valias e menor impacto com as novas aquisições. Processos como: i) auditorias a dados, processos, segurança, outros; ii) migração e reorganização de dados; iii) análise e processamento de dados (*datamining*, etc.); iv) coleta de dados contínuos (streaming) oriundos de infra-estruturas da Internet das Coisas, tais como sensores em máquinas de linhas industriais; v) recomendações e previsões sobre estados com processamento recorrendo a *big data* e mesmo a inteligência artificial, são exemplo de cenários onde processos de ETL poderão desempenhar papel preponderante.

No contexto emergente dos *smart environments* (*Cities, Health Care, Social*, etc.) a evidência deste tipo de soluções é clara e crescente. A integração de soluções ditas mais inteligentes, que reagem a eventos, em processos existentes ou mesmo legados, são desafios constantes.

Pretende-se que se defina o objetivo a explorar no trabalho que poderá ser real ou imaginário. No [drive](#), cada aluno deve registar: o tema do trabalho; a(s) plataforma(s) que pretende utilizar; email e o repositório git utilizado.

¹ <https://nodered.org/>

² <https://www.home-assistant.io/>

OBJETIVOS

Os objetivos do desenvolvimento deste trabalho são os seguintes:

- Consolidar conceitos associados à Integração de Sistemas de Informação usando Dados;
- Analisar e especificar cenários de aplicação de processos de ETL;
- Explorar ferramentas de suporte a processos de ETL;
- Explorar novas Tecnologias, Frameworks ou Paradigmas;
- Potenciar a experiência no desenvolvimento de software;
- Facilitar a assimilação do conteúdo da Unidade Curricular.
- Contribuir para qualidade da escrita de relatórios

MODELO DE FUNCIONAMENTO

- O trabalho poderá ser realizado quer de forma individual, quer em grupo de dois elementos. No caso de um grupo de dois elementos, cada elemento deve explorar uma plataforma diferente. A defesa do trabalho será individual.
- A plataforma de desenvolvimento pode ser a que o aluno pretender, desde que suporte os processos de ETL identificados.
- O processo a desenvolver por cada aluno/grupo deve ser estruturado em três fases obrigatórias, demonstrando a capacidade de interligar diferentes tecnologias e paradigmas ao longo do ciclo de vida dos dados:

- **Fase 1:** Recolha e Preparação de Dados: Origens e Formatos Diversos – (“E”)

Nesta fase, pretende-se explorar a recolha e disponibilização de dados a partir de múltiplas fontes heterogéneas antes do seu processamento principal.

- *Diversidade de Formatos:* O fluxo deve importar/consumir dados em pelo menos 2 ou 3 formatos distintos (ex.: CSV, JSON, XML, YAML).
- *Diversidade de Fontes de Dados:* Exploração de origens de dados de natureza variada, tais como:
 - Ficheiros locais ou remotos;
 - Bases de Dados Relacionais (ex.: PostgreSQL, MySQL) e NoSQL (ex.: MongoDB);
 - Dispositivos ou fluxos de dados contínuos (*streaming*) via Node-RED ou Brokers MQTT (ex.: Mosquitto);
 - Chamadas a APIs REST / Web Services externos.

- **Fase 2:** Processamento e Transformação de Dados – Lógica de negócio (“T”)

Nesta fase, a ferramenta escolhida (Pentaho Kettle, KNIME, Talend, etc.) executa ações de transformação dos dados:

- *Limpeza e Validação de Dados:* Identificação de valores nulos, remoção de duplicados, anonimização e aplicação de Expressões Regulares (Regex) para validação/normalização de texto.

- *Conversão de Formatos e Estruturas:* Transformação entre formatos de dados (ex.: XML → JSON, CSV → documento PDF de relatório, etc.).
- *Outras operações:*
 - *Cruzamento e fusão de dados (Joins, Lookups, Merge);*
 - *Agrupamentos (Aggregations), cálculos, ordenação e seleção/filtragem condicional;*
 - *Mapeamento e reestruturação de schemas.*

○ **Fase 3:** Persistência e Exportação - Destinos, Notificações e outros – (“L”)

Nesta fase, os dados transformados e os resultados de eventuais processos de validação são encaminhados para outros sistemas. Ações possíveis:

- *Carregamento e Persistência dos Dados*
 - *Persistência em Bases de Dados:* Inserção ou atualização dos dados resultantes em BDs de destino (SQL, NoSQL, Data Warehouses / Data Marts);
 - *Geração de Ficheiros de Exportação:* Exportação dos dados processados em SQL (para usar em dumps/inserts), JSON, CSV, XML, Apache Parquet, etc.
 - *Notificação, Alertas e Suporte a Decisão:*
 - Envio automático de relatórios, resumos ou alertas de erro por e-mail;
 - Transferência e disponibilização dos ficheiros exportados em servidores remotos (FTP / SFTP).
 - *Visualização Dinâmica e Streaming:* Alimentação de Dashboards em tempo real para monitorização e apresentação de resultados (ex.: via Node-RED Dashboard, Grafana, Power BI ou Home Assistant).
- Os processos a desenvolver são do critério do aluno. Contudo, nesses processos são critérios de mais-valia:
- Utilização de Expressões Regulares (ER) em processos de tratamento de dados tais como: normalização, limpeza, composição, etc;
 - Lidar com importação/exportação (serialização) de dados de/para XML, JSON, YAML;
 - Desenvolver *Jobs* ou *Process Controls* onde se consiga definir um projeto completo envolvendo acesso a serviços remotos como *ftp*, *email*, outros;
 - Joins, Agrupamentos, Lookups
 - Operações sobre valores: concatenar, separar, calcular, substituir, ordenar, “eliminar”, converter, selecionar, filtrar, validar, clonar, anonimizar, normalizar, corrigir.
 - Geração de Logs
 - Explorar o acesso a APIs (exemplo: serviços web) remotas;
 - Operações essenciais sobre Bases de Dados.
 - Processos de visualização dos resultados conseguidos utilizando *dashboards*, se necessário com a integração de outras ferramentas como NodRed, Apache Airflow® , Home Assistant, ou outras.
- O trabalho deverá ser entregue até ao dia **22 de outubro**, através de submissão na plataforma de e-learning;
- O trabalho deve fazer-se acompanhar de um **Relatório final** que documente devidamente todo o trabalho desenvolvido, nomeadamente:

1. Enquadramento
Equipa, Unidade Curricular, Curso
 2. Problema
Descrição do que se pretende demonstrar e/ou resolver
 3. Estratégia utilizada
Que operadores e processos estarão envolvidos
 4. Transformações
Diagramas
Explicação
 5. Jobs
Diagramas
Explicação
 6. Vídeo com demonstração (QR Code)
 7. Conclusão e Trabalhos futuros
 8. Referências bibliográficas utilizadas, incluindo referências web que tenham sido relevantes.
- O trabalho será apresentado presencialmente e individualmente ao docente em data a combinar com cada aluno.
 - Cada aluno deverá ainda criar um repositório Git onde deverá colocar também todo o material produzido durante o trabalho.

CRITÉRIOS DE AVALIAÇÃO

São critérios de avaliação do trabalho

1. Qualidade do trabalho produzido
 - Originalidade do trabalho
 - Pertinência e Dificuldade do Problema a resolver
 - Diversidade de Operadores de Transformação
 - Diversidade de formatos de representação de dados
 - Utilização de Expressões Regulares (ER), Normalização de dados, *Merging* de dados
 - Orquestração de processos de transformação desenvolvidos

- Todos os restantes critérios de mais-valia indicados acima no modelo de funcionamento

2. Qualidade da Apresentação e Relatório do trabalho

Bom Trabalho

Luís Ferreira & Óscar Ribeiro